Εργασία: Μηχανή αναζήτησης άρθρων σχετικών με τον COVID-19

Παράδοση Εργασίας

Κωνσταντίνος Κρανάς, 2278

Folder Structure:

src

- > filtered
- > sampled
- > index*
- > IndexFiles.java
- > GUI.java
- > parseFilesWithDate.py

To script **parseFilesWithDate.py** φορτώνει τα αρχεία json του φακέλου **sampled** και δημιουργεί τα φιλτραρισμένα αρχεία στον φάκελο **filtered**.

To IndexFiles.java διατρέχει τα αρχεία του φακέλου **filtered** και δημιουργεί το ευρετήριο.

Η εφαρμογή τρέχει από το **GUI.java**, όπου δημιουργεί το γραφικό περιβάλλον και υλοποιεί την εύρεση εγγράφων.

How to build: Compile IndexFiles.java and GUI.java, run IndexFiles to create the index, and then run GUI. To GUI υλοιποιήθηκε με Swing.

Συλλογή εγγράφων: Τα έγγραφα προέρχονται από το dataset CORD-19 (https://www.semanticscholar.org/cord19)

Προεπεξεργασία του dataset (parseFilesWithDate):

Από κάθε αρχείο του φακέλου **sampled** εξάγονται οι πληροφορίες κωδικού(paper_id), τίτλου(title), συγγραφέων(authors), ημερομηνία έκδοσης(date), ιδρυμάτων(institutions) και του περιεχομένου(text), και εισάγονται σε γραμμές στα αρχεία του φακέλου **filtered.**

Indexing:

Τα αρχεία από το φάκελο **filtered** δημιουργούν Documents με fields "paper_id", "title", "authors", "date", "institutions" και "text" (default).

^{*:} Ο φάκελος **index** δημιουργείται αφού τρέξει το IndexFiles.java.

Searching:

Οι λειτουργίες του Indexing και του Searching είναι απλές. Πάντα γίνεται search με βάση το text, στο οποίο εκτός από τα περιεχόμενα υπάρχουν και πληροφορίες για τα fields. Αν ο χρήστης εισάγει title, authors, institutions, γίνεται επίσης search στα αντίστοιχα fields. Τα fields date, paper_id δεν παίζουν ρόλο στο search, υπήρχαν λίγα dates.

Σε multiple field query, επιστρέφει το OR τους.

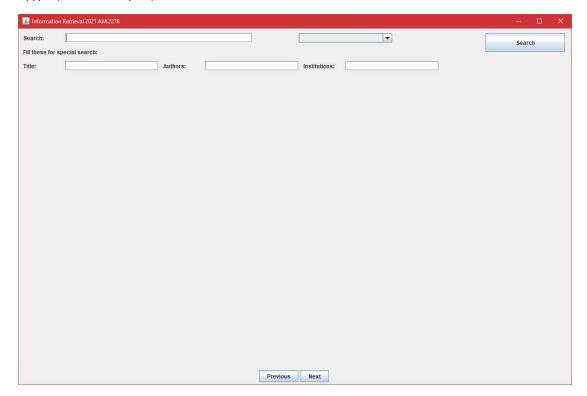
Η εύρεση περιορίζεται στα 100 πρώτα.

History:

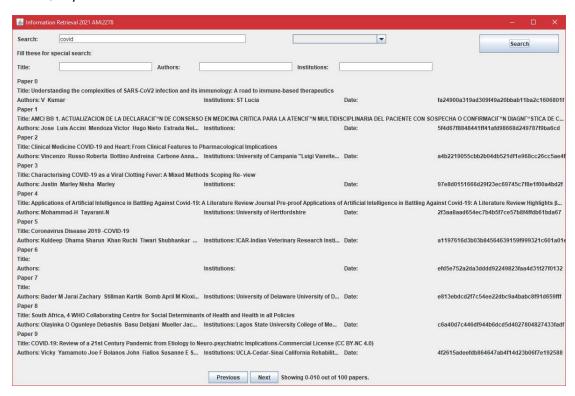
Η εφαρμογή κρατάει ιστορικό του text query.

Demo:

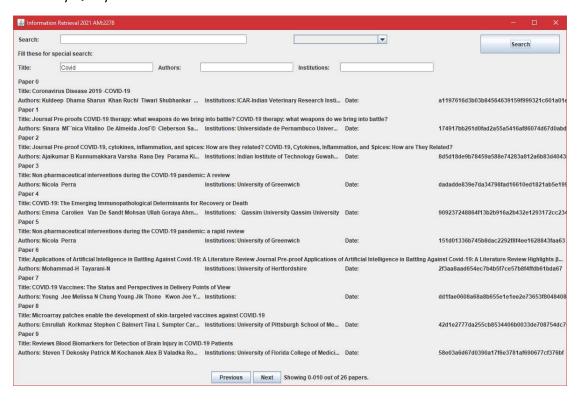
Με τη χρήση των κουμπιών next/prev εμφανίζει την επόμενη/προηγούμενη δεκάδα εγγράφων που ταιριάζον.



Text Query:



Title Only Query:



History:

